

MAKİNE ÖĞRENMESİ YÖNTEMLERİ İLE SOLUNUM YOLU HASTALIKLARININ VE ÇEVRESEL RİSK FAKTÖRLERİNİN ÇOK BOYUTLU ANALİZİ: CDC BRFSS VERİ SETİ ÖRNEĞİ

ÖZ

Bu çalışmada, yetişkin nüfustaki kronik rahatsızlıkları ve davranışsal risk faktörlerini izleyen Centers for Disease Control and Prevention (CDC) bünyesindeki Behavioral Risk Factor Surveillance System (BRFSS) 2024 veri seti kullanılarak solunum yolu hastalıklarının tahmini amaçlanmıştır. Araştırma kapsamında, solunum yolu enfeksiyonları ve astım dikeyinde coğrafi konum, kronik solunum rahatsızlıkları geçmiş ve fiziksel aktivite düzeyleri arasındaki ilişkiler çok boyutlu olarak incelenmiştir. Veri setinde yer alan anket kaynaklı geçersiz ve eksik verilerin giderilmesinde, müfredat kapsamında ele alınan K-En Yakın Komşuluk (KNN) tabanlı eksik değer atama (imputation) metodolojisi kullanılmıştır. Temizlenen veri seti üzerinde genelleme yeteneği yüksek bir sınıflandırma modeli geliştirmek amacıyla veri sızması (data leakage) engellenerek %80 eğitim ve %20 test ayrımı yapılmış, ardından öznitelik ölçeklendirme uygulanmıştır. Model kurgusunda KNN algoritması tercih edilmiş ve en uygun hiperparametrelerin belirlenmesi amacıyla 5 katmanlı çapraz doğrulama (5-fold Cross-Validation) içeren Grid Search optimizasyonu yürütülmüştür. Optimizasyon sonucunda en yüksek başarıyı veren komşu sayısı $k=31$ ve ağırlık fonksiyonu uzaktaki gözlemleri cezalandıran "distance" yöntemi olarak tespit edilmiştir. Geliştirilen nihai model test verisi üzerinde %84,35 doğruluk, 0,7962 F1 skoru ve 0,5551 ROC-AUC skoru elde etmiştir. Sonuçlar, sağlık verilerindeki yapısal sınıf dengesizliğinin (class imbalance) azınlık sınıfları üzerindeki tahmin başarısını nasıl sınırladığını ortaya koymakta ve sorumlu yapay zeka perspektifinden epidemiyolojik modelleme kısıtlılıklarını tartışmaktadır.

Anahtar Kelimeler: Makine Öğrenmesi, KNN, BRFSS, Solunum Yolu Hastalıkları, Hiperparametre Optimizasyonu.

1. GİRİŞ

Solunum yolu hastalıkları, küresel ölçekte morbidite ve mortalite oranlarını doğrudan etkileyen, bireylerin yaşam kalitesini düşüren ve halk sağlığı sistemleri üzerinde kalıcı sosyoekonomik yükler oluşturan kronik sağlık problemlerinin başında gelmektedir. Astım ve kronik obstrüktif akciğer hastalığı (KOAH) gibi rahatsızlıklar; genetik yatkınlıkların yanı sıra bireylerin yaşadığı coğrafi çevre, hava kalitesi, sosyoekonomik durum ve düzenli fiziksel aktivite alışkanlıkları gibi çok varyanslı çevresel risk faktörleriyle doğrudan ilişkilidir. Geleneksel istatistiksel yöntemler, bu denli büyük ve çok boyutlu epidemiyolojik veri havuzlarındaki doğrusal olmayan karmaşık ilişkileri ortaya çıkarmakta yetersiz kalabilmektedir.

Modern veri bilimi ve makine öğrenmesi paradigmaları, "Veri + Çıktı = Kurallar" denklemi üzerinden hareket ederek büyük anket sistemlerinden anlamlı ve yönlendirici tıbbi örüntüler çıkarılmasını mümkün kılmaktadır. Bu doğrultuda, makine öğrenmesi algoritmalarının önleyici tıp ve halk sağlığı politikalarındaki rolü her geçen gün

artmaktadır. Bu çalışmanın amacı, dünyanın en büyük sürekli sağlık anket sistemi olan CDC BRFSS 2024 verileri üzerinden, bireylerin solunum yolu sağlığını etkileyen çevresel ve davranışsal faktörleri K-En Yakın Komşuluk (KNN) algoritması vasıtasıyla modellemek ve en yüksek genelleme (generalization) kapasitesine sahip parametre kurgusunu akademik standartlarda ortaya koymaktır.

2. YÖNTEM

Veri Seti ve Değişken Seçimi

Araştırmada kaynak olarak CDC tarafından paylaşılan ve yaklaşık 457.670 bireye ait anket verilerini barındıran 2024 yılı Behavioral Risk Factor Surveillance System (BRFSS) veri seti kullanılmıştır. Devasa boyuttaki bu veri havuzundan Solunum Yolu Hastalıkları dikeyine odaklanabilmek adına amaca yönelik 4 temel öznelik izole edilerek 10.000 gözlemden oluşan bir alt örneklem oluşturulmuştur:

- **ASTHMA3 (Hedef Değişken):** Bireyin astım hastası olup olmadığını belirten ikili sınıflandırma etiketi (1: Astım, 0: Sağlıklı).
- **_STATE (Bağımsız Değişken):** Bireyin yaşadığı eyaleti temsil eden kategorik coğrafi kod.
- **CHCCOPD3 (Bağımsız Değişken):** Katılımcının KOAH, kronik bronşit veya amfizem geçmişini gösteren tıbbi veri.
- **EXERANY2 (Bağımsız Değişken):** Bireyin son 30 gün içinde iş dışı fiziksel aktivite veya egzersiz yapma durumunu gösteren davranışsal metrik.

Veri Ön İşleme ve Keşifsel Veri Analizi (EDA)

Gerçek dünya veri setlerinin en büyük kısıtlarından biri olan geçersiz anket yanıtları ve eksik veriler, model başarısını doğrudan gölgelemektedir. Ham veri setinde katılımcıların "Bilmiyorum/Emin Değilim" veya "Reddedildi" şeklinde verdiği tüm geçersiz yanıtlar NaN (Not a Number) olarak işaretlenmiştir. Eksik verilerin doldurulması için K-En Yakın Komşuluk (KNN) tabanlı Imputer mimarisi ($k=5$) kullanılmıştır. İkili sınıflandırma metriklerinin (Log Loss vb.) doğru çalışabilmesi adına hedef değişken sınıfları makine öğrenmesi standartlarına (0 ve 1) dönüştürülmüştür.

Model Kurgusu ve Hiperparametre Optimizasyonu

Modelin eğitim aşamasında test verilerini görerek "ezberleme" (overfitting) hatasına düşmesini engellemek ve kesin bir "genelleme" performansı ölçebilmek adına, veri sızması (data leakage) kontrolleri yapılarak veri seti %80 Eğitim ve %20 Test olarak ikiye ayrılmıştır. Veri sızmasını önlemek adına StandardScaler nesnesi yalnızca eğitim seti üzerinde eğitilmiş ve ardından her iki sete uygulanarak Z-Skoru standardizasyonu yapılmıştır:


$$z = \frac{x - \mu}{\sigma}$$

Model başarısını ölçen metrik olarak ROC-AUC skoru hedef seçilmiş ve en yüksek başarıyı sunan KNN parametrelerini bulmak için 5 katmanlı GridSearchCV mimarisi işletilmiştir. Optimizasyon sonucunda standart Öklid mesafesi formülü baz alınarak en ideal komşu sayısı $k=31$ ve ağırlıklandırma stratejisi "distance" olarak tespit edilmiştir:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

3. BULGULAR

Makine öğrenmesi modellerinin eğitime geçilmeden önce, bağımsız değişkenlerin astım hastalığı (ASTHMA3) üzerindeki tahmin gücünü ölçmek amacıyla Keşifsel Veri Analizi (EDA) yürütülmüş ve değişkenler arası korelasyon matrisi Şekil 1'de sunulmuştur.




Şekil 1. Seçilen Öznitelikler Arasındaki Korelasyon Matrisi Şekil 1'de sunulan bulgular incelendiğinde, bağımsız değişkenlerin hedef değişken üzerindeki doğrusal etkisinin oldukça zayıf olduğu görülmektedir. En belirgin ilişki, KOAH (CHCCOPD3) ile astım arasında (-0.19) gözlemlenmiştir. Eyalet ve fiziksel aktivite verilerinin hedef

değişkenle neredeyse sıfıra yakın (sırasıyla -0.01 ve 0.04) korelasyon göstermesi, veri setindeki özniteliklerin tahmin gücünün sınırlı olduğunu kanıtlamaktadır.

Bu veri kısıtlılığı altında farklı makine öğrenmesi mimarilerinin performanslarını kıyaslamak amacıyla Lojistik Regresyon, Karar Ağaçları, Random Forest, Yapay Sinir Ağları (MLP) ve optimize edilmiş KNN algoritmaları test verisi üzerinde çalıştırılmış; elde edilen karşılaştırmalı metrikler Tablo 1'de ve ROC-AUC eğrileri Şekil 2'de detaylandırılmıştır.

TABLO-1:

Model Adı	Doğruluk (Accuracy)	F1 Skoru (Weighted)	ROC- AUC Skoru	Log Loss	MSE (Hata)
Lojistik Regresyon (Baseline)	%85,05	0,7822	0,5513	0,4220	0,1495
Karar Ağacı (Baseline)	%72,80	0,7670	0,5115	9,8037	0,2720
Random Forest (Gelişmiş)	%84,35	0,7950	0,5330	0,5440	0,1565
Yapay Sinir Ağı (MLP)	%85,05	0,7822	0,5467	0,4195	0,1495
KNN (Optimize Edilmiş)	%84,35	0,7962	0,5551	-	0,1565



Şekil 2. Makine Öğrenmesi Modellerinin Karşılaştırmalı ROC-AUC Eğrileri Şekil 2'deki performans eğrileri, verideki aşırı sınıf dengesizliğinin yalnızca optimize edilmiş KNN algoritmasını değil, Random Forest ve MLP gibi karmaşık mimarileri de sınırlandırdığını göstermektedir. Tüm modellerin eğrilerinin 0.58 bandında kümelenmesi ve rastgele tahmin çizgisine (siyah kesik çizgi) yakın seyretmesi, sorunun algoritmik bir zayıflıktan ziyade azınlık sınıfı yetersizliğinden kaynaklandığını doğrulamaktadır. Sınıf bazlı bu tahmin problemini netleştirmek adına, projede hedeflenen optimize edilmiş KNN modelinin konfüzyon matrisi Tablo 2'de sunulmuştur.

Gerçek / Tahmin Durumu	Sınıf 1 (Tahmin: Astım)	Sınıf 0 (Tahmin: Sağlıklı)	Toplam Gözlem (Support)
Sınıf 1 (Gerçek: Astım)	22 (True Positive)	277 (False Negative)	299
Sınıf 0 (Gerçek: Sağlıklı)	35 (False Positive)	1666 (True Negative)	1701

Tablo 2 incelendiğinde, modelin "Sağlıklı" olan 1701 bireyin 1666'sını doğru sınıflandırarak bu sınıfta yüksek bir duyarlılık elde ettiği görülmektedir. Buna karşın, asıl

azınlık sınıfı olan "Astım" kategorisindeki 299 hastanın yalnızca 22'si doğru tespit edilebilmiştir. Bu durum, modelin çoğunluk sınıfına doğru aşırı uyum (overfitting) gösterdiğini kanıtlamaktadır.

4. TARTIŞMA VE SONUÇ

Bu çalışmada elde edilen bulgular, sağlık politikaları açısından değerlendirildiğinde epidemiyolojik modellemelerin sahip olduğu temel kısıtlılıkları açıkça ortaya koymaktadır. Geliştirilen K-En Yakın Komşuluk (KNN) modeli, veri setindeki sınıf dengesizliğinin (class imbalance) doğrudan bir sonucu olarak çoğunluk sınıfına aşırı uyum (overfitting) göstermiştir. Sağlık sistemlerinde bir makine öğrenmesi modelinin gerçek hastaları sağlıklı olarak etiketlemesi (Yalancı Negatif / False Negative oranının yüksekliği), erken teşhis süreçlerini geciktireceği için klinik uygulamalarda kabul edilemez bir risk oluşturmaktadır. Modelin %84,35 gibi yüksek bir doğruluğa sahip görünmesi istatistiksel bir yanılsamadır; zira modelin asıl odaklanması gereken azınlık sınıfını (astımlı bireyleri) tespit etmedeki başarısı oldukça düşüktür. Çalışmanın temel kısıtlılıkları arasında, hedeflenen solunum yolu hastalığını tahmin etmek için modele yalnızca yaşanan eyalet, KOAH geçmişi ve egzersiz durumu gibi sınırlı sayıda bağımsız değişkenin verilmiş olması yer almaktadır. Gelecek çalışmalarda, SMOTE (Synthetic Minority Over-sampling Technique) gibi sentetik veri üretme teknikleri ile sınıfsal dengesizliklerin algoritmik olarak giderilmesi hedeflenmelidir. Buna ek olarak, hava kalitesi endeksi, sigara kullanımı ve sosyoekonomik durum gibi solunum sağlığını doğrudan etkileyen diğer özniteliklerin modele dahil edilmesi, algoritmanın tanısallık kapasitesini artıracaktır.

5. SORUMLU YAPAY ZEKA VE ETİK BİLDİRİMLER

Makine öğrenmesi modellerinin geliştirilme sürecinde algoritmik yanlılık (bias) ve etik boyutların değerlendirilmesi, modelin salt matematiksel performansından bağımsız olarak büyük bir önem taşımaktadır. Bu projenin sonuçları, sorumlu yapay zeka denetim listesi kriterlerine göre derinlemesine incelenmiştir.

İlk olarak, veri setindeki istatistiksel azınlık grubunun (astım hastalarının) model tarafından matematiksel olarak görmezden gelindiği ve bu grup için anlamlı tahminler üretilmediği tespit edilmiştir. Bu durum, modelin gerçek bir karar destek sistemi olarak kullanılması halinde, astımlı bireylerin önleyici sağlık hizmetlerine erişimini görünmez kılacak algoritmik bir yanlılık barındırdığını kanıtlamaktadır.

İkinci olarak, çalışmanın değişken seçiminde ırk veya yaş gibi doğrudan "duyarlı özellikler" (sensitive features) modele dahil edilmemiş olsa da, kullanılan coğrafi "eyalet" (_STATE) değişkeninin dolaylı olarak sosyoekonomik düzey veya demografik köken için bir vekil (proxy) değişken olarak çalışma riski mevcuttur. Belirli eyaletlerin hastalıklarla güçlü korelasyonlar göstermesi, sağlık sigortası primlerinin algoritmik olarak bölgesel bazda artırılması gibi etik ihlallere zemin hazırlayabilir.

Son olarak, kullanılan BRFSS veri seti her ne kadar bireysel bazda tamamen anonimleştirilmiş olsa da, belirli coğrafi bölgelerin veya davranışsal profillerin kronik hastalıklarla algoritmik düzeyde yüksek oranda ilişkilendirilmesi, toplumsal bir damgalamaya (stigmatization) yol açma riski taşımaktadır. Bu nedenle, üretilen

istatistiksel bulguların kesin bir nedensellik (causality) deęil, yalnızca gözlemsel bir korelasyon sunduęu şeffaf bir şekilde beyan edilmelidir.

KAYNAKÇA

Centers for Disease Control and Prevention. (2024). *Behavioral Risk Factor Surveillance System survey data* [Data set]. U.S. Department of Health and Human Services, Kaggle.